

resumen numérico de bases de datos

David Flores

2026-06-16

Resumen numérico de las bases de datos “t5_p1 a t5_p5”

Primero se necesitan descargar las bases de datos y cargarlas en el espacio de trabajo para empezar con el análisis exploratorio.

Posteriormente con la función de *summary* obtenemos las medidas centrales como media, mediana, primer y tercer cuartil así como los valores máximos y mínimos presentes en los datos dandonos su rango

```
summary(datos1$edad)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.80   2.75   15.85   19.46   30.60   67.40
```

```
summary(datos2$Edad)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      9.00   9.75   11.25   11.29   12.62   13.75
```

```
summary(datos3$TR)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      3.634   5.705   7.465   8.845   11.702   19.437
```

```
summary(datos5$Cancer)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.0000  0.0000  0.0000  0.4516  1.0000  1.0000
```

Esto nos deja observar que la mediana y la media tienen valores cercanos entre si lo que indica que en mayor o menor medida tienen una distribución simétrica

```
summarySE(data=datos1, measurevar= "edad")
```

```
##      .id N  edad      sd      se      ci
## 1 <NA> 50 19.46 17.81711 2.51972 5.063566
```

```
summarySE(data=datos2, measurevar= "Edad")
```

```
##      .id  N      Edad      sd      se      ci  
## 1 <NA> 24 11.29167 1.677321 0.3423817 0.7082705
```

```
summarySE(data=datos3, measurevar="TR")
```

```
##      .id  N      TR      sd      se      ci  
## 1 <NA> 30 8.8445 4.193802 0.7656801 1.565992
```

```
summarySE(data=datos5, measurevar="Cancer")
```


```
##      .id  N      Cancer      sd      se      ci  
## 1 <NA> 124 0.4516129 0.4996721 0.04487188 0.08882113
```

Con la función de *summarySE* obtenemos las medidas de dispersión como la desviación estándar y el error estándar así como el intervalo de confianza presente en cada una de las bases de datos


Resumen gráfico

Se realizó un gráfico de boxplot para visualizar la posible distribución de todas las bases datos a través de la mediana


```
boxplot (datos1$edad)
```




```
boxplot(datos2$Edad)
```



```
boxplot(datos3$TR)
```




```
boxplot(datos5$Cancer)
```



En el caso de las bases de datos **t5_p1**, **t5_p2** y **t5_p3** se observa un sesgo positivo donde la distribución se inclina a la derecha principalmente por un alto número de valores bajos, sin embargo, para la base de datos **t5_p5** esto no sucede porque los valores solamente son 1 y 0. Esto se comprobó al realizar un histograma de las mismas bases


```
hist(datos1$edad)
```

Histogram of datos1\$edad




```
hist(datos2$Edad)
```

Histogram of datos2\$Edad




```
hist(datos3$TR)
```

Histogram of datos3\$TR



```
hist(datos5$Cancer)
```

Para finalizar el análisis exploratorio se realizó una prueba de shapiro para evaluar la hipótesis nula sobre la distribución, en donde se observa que la probabilidad de obtener esa distribución es muy baja en todos los casos, lo que significa que no tienen una distribución normal, algo que se observó en los anteriores apartados.

```
shapiro.test(datos1$edad)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  datos1$edad  
## W = 0.8833, p-value = 0.0001411
```

```
shapiro.test(datos2$Edad)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  datos2$Edad  
## W = 0.86452, p-value = 0.004116
```

```
shapiro.test(datos3$TR)
```

```
##  
##  Shapiro-Wilk normality test
```

```
##  
## data:  datos3$TR  
## W = 0.90056, p-value = 0.00867
```

```
shapiro.test(datos5$Cancer)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  datos5$Cancer  
## W = 0.63298, p-value = 3.754e-16
```